Tech Challenge — Fase 02

Predição de Aprovação de Pedidos de Cartão de Crédito

Machine Learning para apoio à decisão de crédito

Turma	Grupo
Data Analytics BB	35

Integrantes

Fernanda Arruda Pimenta da Silva	RM377753
Guilherme Caetano Peron	RM377756
Alexandre dos Anjos de Jesus	RM377732
Nathalia Fernanda dos Santos Gelais	RM377743
Didan Junqueira Ribeiro	RM377825

33.110

clientes na base analítica

12,96%

classe de maior risco

maus pagadores

79,80%

ROC-AUC no teste final

Modelo final: Random Forest + Class Weight

Contexto e objetivo

Aprovação de cartão exige equilibrar risco de crédito e oportunidade de negócio.

💳 Problema de negócio

Identificar perfis com maior probabilidade de atraso antes da decisão de crédito.

🎯 Objetivo do estudo

Transformar bases cadastrais e histórico de crédito em evidência preditiva.

🤖 Solução proposta

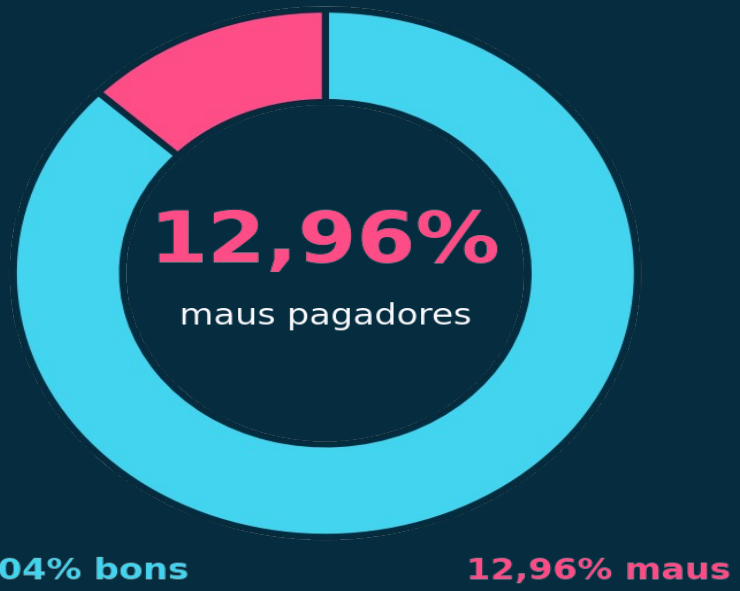
Construir uma pipeline reproduzível com validação e avaliação independente.

Tese do projeto

O modelo não substitui a política de crédito. Ele funciona como apoio à decisão, priorizando análises adicionais para clientes com maior score de risco.

Dados e variável-alvo

A base final ficou desbalanceada, exigindo métricas além da acurácia.



33.110

clientes elegíveis

28.819

bons pagadores

87,04%

4.291

maus pagadores

12,96%

Regra do target

TARGET_BAD = 1 quando o cliente teve pelo menos uma ocorrência de atraso de 30 dias ou mais no histórico observável.

Por que isso importa?

Um modelo que classificasse todos como bons já teria alta acurácia, mas não identificaria nenhum mau pagador.

Metodologia

Pipeline completa, validação cruzada e teste final preservado.

1 Integração das bases

2 Tratamento e features

3 Split estratificado

4 Modelagem e balanceamento

5 Validação 5-fold CV

6 Teste final independente

Modelos avaliados

KNN • Decision Tree • Random Forest • SVM

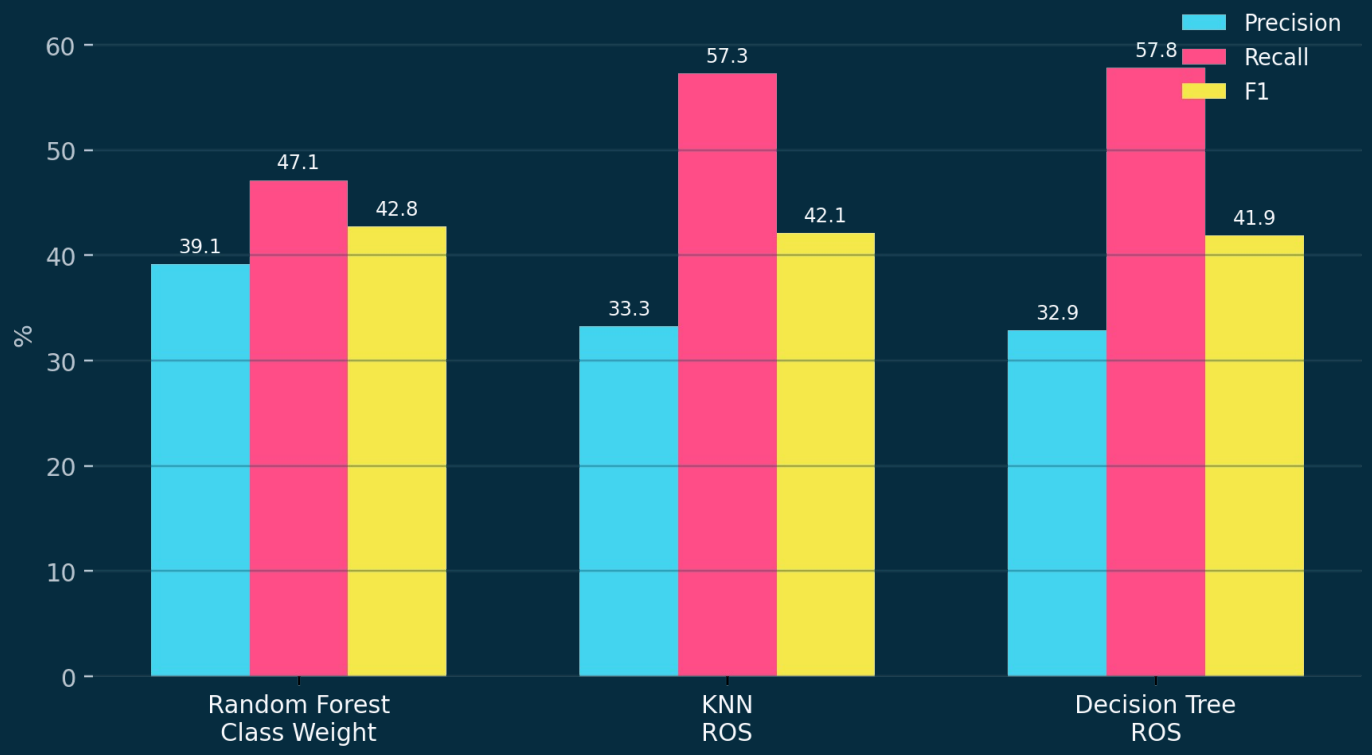
Estratégias de desbalanceamento

Class Weight • OverSampling • UnderSampling • SMOTENC

Teste final ficou isolado até a escolha formal do modelo final.

Comparação dos modelos

Random Forest foi escolhida pelo melhor equilíbrio geral, não por uma única métrica.



Modelo selecionado

Random Forest + Class Weight

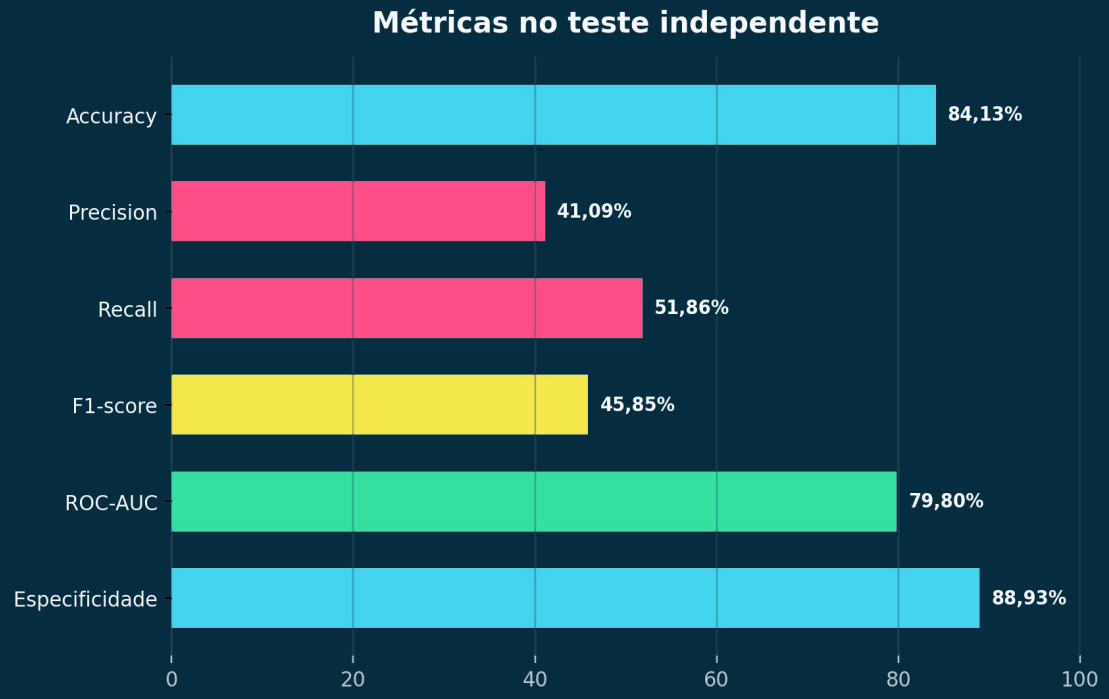
39,13%	47,13%	42,76%
Precision	**Recall**	**F1**

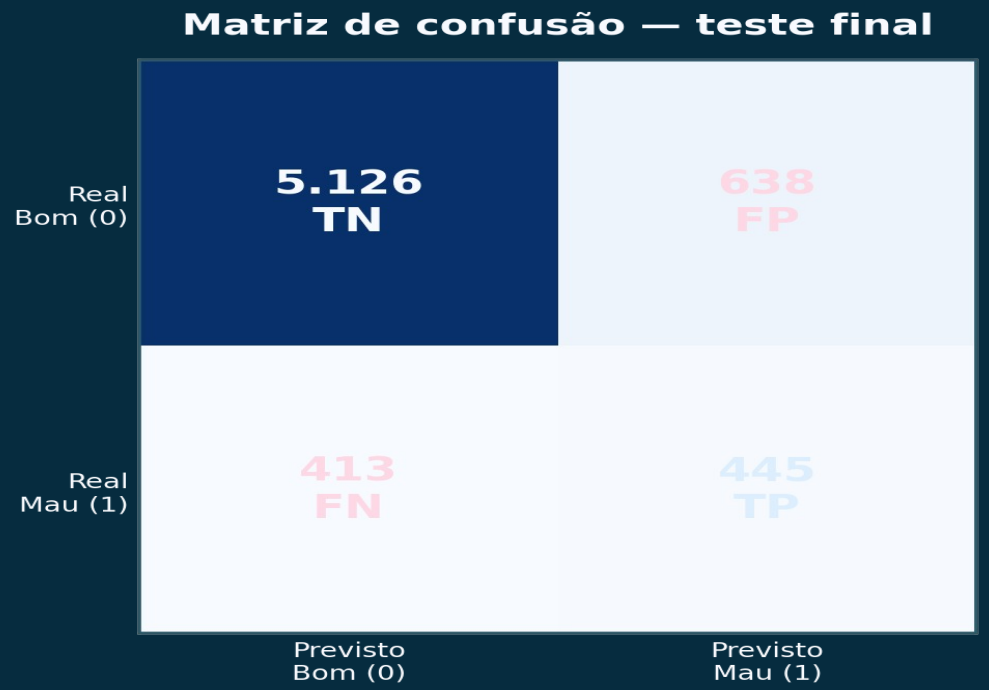
Trade-off observado

Decision Tree e KNN tiveram maior Recall, mas geraram mais falsos positivos. A Random Forest manteve melhor equilíbrio entre risco e preservação dos bons clientes.

Resultado no teste independente

Avaliação realizada uma única vez após a escolha formal do modelo.



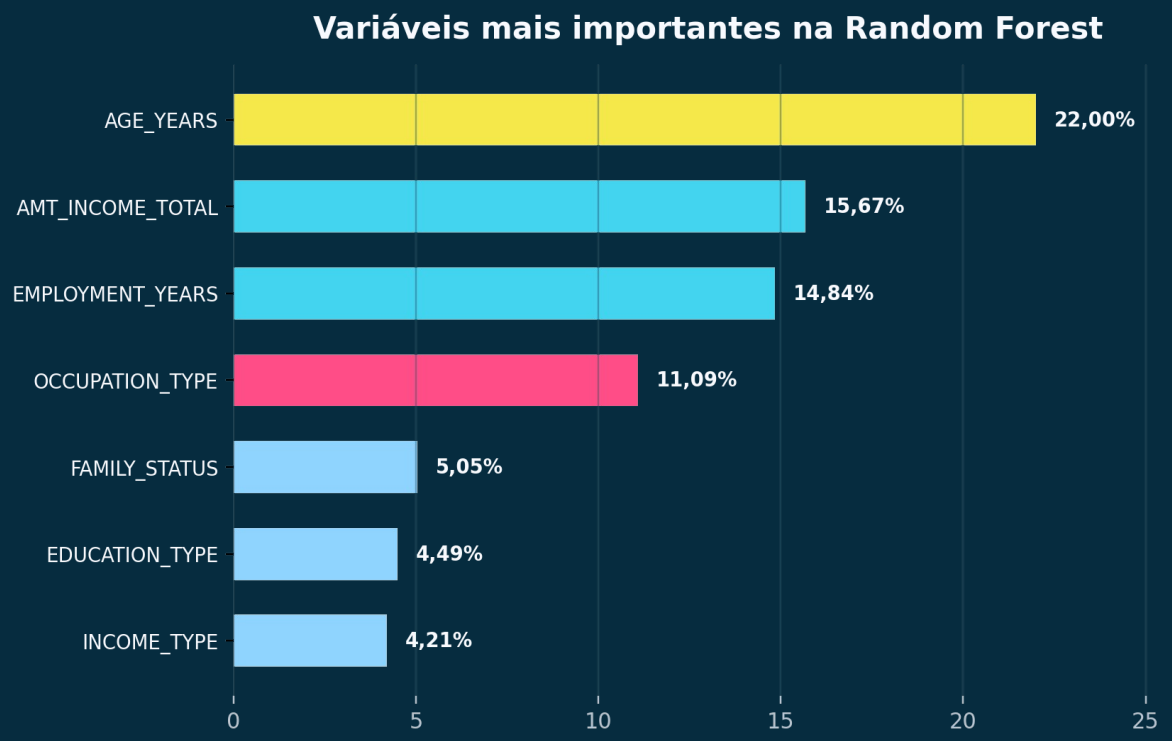


Leitura executiva

O modelo preserva 5.126 dos 5.764 bons pagadores e identifica 445 dos 858 maus pagadores no threshold padrão.

Interpretação do modelo

Importância preditiva ajuda a explicar a decisão, mas não prova causalidade.



Top 3 concentra 52,51%

Idade, renda e tempo de emprego foram as variáveis mais usadas pela Random Forest.

OCCUPATION_TYPE: 11,09%

A agregação das dummies revela a importância da variável ocupação como conjunto.

Cuidado de interpretação

Feature Importance indica relevância preditiva no modelo; não indica causalidade nem direção do efeito.

Conclusões e recomendações

Resultado final é consistente, mas a decisão operacional depende do custo dos erros.

Modelo final

Random Forest + Class Weight

Teste final

F1 45,85%
ROC-AUC 79,80%

Limitação

Recall 51,86%
ainda deixa risco escapar

Ações sugeridas

1 **Usar como apoio à decisão**

priorizar análise adicional de perfis com maior score de risco

2 **Definir custo de FP e FN**

ajustar threshold com base no impacto financeiro real

3 **Monitorar em produção**

acompanhar performance, drift e estabilidade do modelo

Obrigado!

Grupo 35 — Data Analytics BB